GRUPO 4: Calderón, María Belén - Choque, Santiago

Informe del Proyecto: Análisis y Predicción de Siniestros Viales en Motos (Argentina) (2017–2024)

1. Contexto y Objetivos del Proyecto

1.1. Contexto

El presente proyecto nace de la necesidad de comprender y analizar la problemática de los siniestros viales en la República Argentina, enfocándose particularmente en aquellos que involucran a motocicletas. Para lograr esto, se utilizó información proveniente del Sistema de Alerta Temprana (SAT), que forma parte del Sistema Nacional de Información Criminal (SNIC). Este dataset abarca los registros oficiales de muertes y hechos de tránsito ocurridos entre los años 2017 y 2024.

El propósito principal de este análisis no es solo observar lo que ya pasó, sino sentar las bases para entender los patrones espacio-temporales de la siniestralidad, lo que en el futuro permite orientar políticas públicas y medidas preventivas de seguridad vial.

1.2. Objetivo Principal

Desarrollar un modelo predictivo de regresión (comparando algoritmos como **Random Forest Regressor**, **Regresión Lineal** y **Regresión de Poisson**) para estimar la cantidad de siniestros viales que involucran motocicletas en Argentina, basándose en variables espacio-temporales y viales (franja horaria, tipo de lugar, temporada del año y provincia).

1.3. Pregunta de Negocio

Aclaración: En primera instancia, formulamos la pregunta de negocio enfocándonos en la franja horaria y la estación del año. Sin embargo, tras analizar el desempeño inicial del modelo y evaluar los resultados notamos que estas variables tenían un impacto limitado. Por ello, optamos por redefinir las variables predictoras y probar una hipótesis alternativa que permitiera alcanzar un mayor nivel de precisión en las predicciones. (Esto se ve reflejado en la sección 6 del informe)

2. Secuencia Metodológica y Decisiones de Diseño

Paso 1: Carga e Inspección Inicial de Datos

- **Qué se hizo:** Se importaron las librerías esenciales (pandas, numpy, matplotlib, seaborn) y se cargó el archivo CSV (SAT-MV-BU.csv). Se evaluaron las dimensiones iniciales: 58,256 filas y 45 columnas.
- **Decisión y Justificación:** Al inspeccionar los identificadores únicos (id_hecho), se descubrió que existían 28,871 hechos únicos, lo que arrojaba un promedio de 2.02 filas por hecho. Esto ocurre porque el dataset original desglosa la información a nivel de personas (víctimas e imputados). Se determinó que la unidad de análisis correcta sería el hecho vial único para evitar duplicidades en el conteo de siniestros.

Paso 2: Limpieza, Unificación y Filtrado de Datos (El problema de las motos)

- **Qué se hizo:**

1. Se examinaron las columnas de vehículos tanto para víctimas como para inculpados (*victima_vehiculo*, *victima_vehiculo_ampliado*, *victima_vehiculo_otro*, etc.).
2. Se detectó que muchos registros contenían valores como *"Sin determinar"* o *"No corresponde"* en una columna, pero guardaban el valor real en otra (por ejemplo, en campos ampliados u otros).
3. Se programaron funciones personalizadas en Python para unificar estos campos en variables limpias (*vehiculo_victima_unificado* y *vehiculo_inculpado_unificado*).
4. Se filtró estrictamente el dataset para conservar únicamente aquellos registros donde la motocicleta estuviera involucrada (ya sea como vehículo de la víctima o del inculpado).
5. Se eliminaron duplicados basados en el *id_hecho*, priorizando las filas con presencia de motos, reduciendo el conjunto a 13,634 hechos únicos de motos.

Paso 3: Ingeniería de Variables (Feature Engineering)
Para enriquecer el modelo predictivo y responder a la pregunta de negocio, se crearon nuevas variables categóricas:

Temporada del año: Se transformó la variable numérica mes en una estación climática (Verano, Otoño, Invierno, Primavera) mediante una función condicional.

- **Franja horaria:** A partir de la hora exacta del hecho (*hora_hecho*), se extrajo la hora numérica y se segmentó en bloques operativos: Mañana (6 a 12 h), Tarde (12 a 18 h), Noche (18 a 24 h) y Madrugada (0 a 6 h).
- **Tipo de lugar:** Se recuperaron valores etiquetados como *"Sin determinar"* cruzándolos con los nombres de las calles (*calle_nombre*) utilizando expresiones regulares para identificar automáticamente si correspondían a Rutas, Autopistas/Autovías, Avenidas o Calles. Posteriormente, se unificaron variaciones de nombres (mayúsculas, acentos, jurisdicciones) en categorías genéricas y limpias.

Paso 4: Construcción del Dataset Agregado

- **Qué se hizo:** Para aplicar modelos de regresión orientados a conteos, se agrupó el dataset (groupby) utilizando variables clave: *provincia_nombre*, *localidad_nombre*, *franja_horaria*, *temporada*, *tipo_lugar*, *anio* y *mes*. La variable objetivo (y) pasó a ser *cantidad_siniestros_motos* (conteo discreto de siniestros por combinación).
- **Decisión de exportación:** Se automatizó la exportación de este resultado a un archivo de Excel (siniestros_motos_agregado_2024.xlsx).

3. Análisis Exploratorio de Datos (EDA) y Visualizaciones

Durante la fase exploratoria se realizaron gráficos de barras y tablas de frecuencias mediante seaborn y matplotlib. Los hallazgos clave fueron:

Rol de la Moto: Del total de siniestros filtrados, el 84.34% (11,499 hechos) corresponden a motocicletas que sufrieron el impacto como víctimas, mientras que en un 15.66% la moto figuraba como el vehículo inculpado/imputado. Esto evidencia la alta vulnerabilidad del conductor de moto en el tránsito argentino.

1. **Distribución Estacional:** Al analizar la siniestralidad por temporadas, se observa una leve alza durante el Verano (27.04%) y la Primavera (25.62%), frente a Otoño (23.79%) e Invierno (23.55%), lo cual suele correlacionarse con un mayor parque circundante de motos en la calle y condiciones climáticas favorables para el rodado.

4. Machine Learning y Modelado Predictivo

Para cumplir con el objetivo de estimar la cantidad de siniestros viales para el año 2024, el flujo metodológico de *Machine Learning* contempló las siguientes etapas:

Preparación de Matriz de Diseño (X e y):

- **Variable Objetivo (y):** *cantidad_siniestros_motos*.
- **Variables Predictoras (X):** Variables categóricas transformadas (*franja_horaria*, *tipo_lugar*, *temporada*, *provincia_nombre*), las cuales fueron codificadas mediante técnicas de *One-Hot Encoding* o *Label Encoding* para que los algoritmos matemáticos pudiesen interpretarlas.

2. **División de Datos (Train/Test Split):**
   - Se separó el dataset histórico (2017-2023) para entrenamiento y validación, reservando o proyectando las condiciones del año 2024 para la inferencia final requerida por el objetivo del negocio.
3. **Algoritmos Evaluados y Comparativa:**
   - **Regresión Lineal:** Utilizada como modelo base (*baseline*). Al ser una variable de conteo con muchos ceros o valores bajos discretos, la regresión lineal tiende a arrojar valores continuos poco precisos y es sensible a valores extremos.
   - **Regresión de Poisson:** Un modelo lineal generalizedizado (GLM) específicamente diseñado para modelar variables de conteo (como número de siniestros). Se justificó su uso estadístico porque modela la probabilidad de eventos discretos en función de variables predictoras de manera más natural que la regresión lineal convencional.
   - **Random Forest Regressor:** Un algoritmo de aprendizaje automático basado en árboles de decisión en conjunto (*ensemble*). Se seleccionó porque captura relaciones no lineales y complejas interacciones entre variables (por ejemplo, cómo el riesgo en una Autopista cambia drásticamente si es de madrugada en invierno versus de tarde en verano).
4. **Métricas de Evaluación:**
   - Se compararon los modelos utilizando métricas estándar de regresión como el Error Cuadrático Medio (MSE), la Raíz del Error Cuadrático Medio (RMSE) y el Coeficiente de Determinación (R^2).
   - **Resultado de la comparativa:** *Random Forest Regressor* superó a la Regresión Lineal tradicional al reducir el error de predicción y manejar de manera óptima la alta dimensionalidad de las variables geográficas (provincias y localidades). Sin embargo, la

Regresión de Poisson demostró ser una alternativa teóricamente muy sólida y matemáticamente coherente para interpretar tasas de incidencia de siniestros.

5. Reentrenamiento Final y Comparativa de Escenarios

El proyecto está enfocado a realizar la predicción tomando como entrenamiento los años desde 2017 a 2023 y testeando en 2024. Luego quisimos mostrar como varía el modelo entrenando con el total de los datos disponibles, para ello incorporamos el año 2024.

	provincia_nombre	franja_horaria	temporada	tipo_lugar	Pred_Original_2023	Pred_Reentrenado_Full	Real_2024
17	Buenos Aires	Tarde	Otoño	Calle	1.08	1.07	1
32	Buenos Aires	Madrugada	Invierno	Calle	1.01	1.01	1
33	Buenos Aires	Madrugada	Otoño	Calle	1.12	1.11	1
38	Buenos Aires	Madrugada	Primavera	Otro / Genérico	1.00	1.06	1
45	Buenos Aires	Mañana	Otoño	Calle	1.06	1.05	1
50	Buenos Aires	Mañana	Verano	Calle	1.06	1.07	1
55	Buenos Aires	Noche	Invierno	Otro / Genérico	1.08	1.14	1
60	Buenos Aires	Noche	Otoño	Calle	1.08	1.07	1
61	Buenos Aires	Noche	Otoño	Calle	1.08	1.07	1
88	Buenos Aires	Noche	Primavera	Calle	1.09	1.11	1
97	Buenos Aires	Madrugada	Otoño	Otro / Genérico	1.00	1.00	1
101	Buenos Aires	Madrugada	Primavera	Otro / Genérico	1.00	1.06	1
104	Buenos Aires	Madrugada	Verano	Calle	1.09	1.08	1
117	Buenos Aires	Mañana	Primavera	Otro / Genérico	1.07	1.06	1
124	Buenos Aires	Noche	Invierno	Calle	1.10	1.10	1

Interpretación de la tabla:

- Un modelo entrenado de 2017 a 2023 para evaluar su capacidad predictiva real sobre 2024 (Pred_Original_2023).
- Un modelo reentrenado con todo el histórico (2017 a 2024) para capturar la máxima información posible (Pred_Reentrenado_Full).
- El valor Real de 2024 para contrastar ambos escenarios.

También creamos un caso hipotético para consultar al modelo:

¿Cuántos siniestros se estiman en la Provincia de Buenos Aires, durante la Noche, en Verano y en una Ruta?

6. Análisis de modelos con otras variables

Luego de observar los resultados optamos por probar con otras variables predictoras para ver si mejoraban las predicciones. Las variables seleccionadas son:

Variables predictoras (x):

- Mes (`mes`) — Mes en el que se registra el hecho.
- Año (`anio`) — Año en el que se registra el hecho.
- Provincia (provincia_nombre) - Provincia donde se registra el hecho

7. Conclusiones

1. **Viabilidad Técnica:** El proyecto demostró que es posible estructurar bases de datos masivas y dispersas (como los registros del SNIC) transformándolas, mediante una cuidadosa ingeniería de datos, en un formato apto para algoritmos predictivos.
2. **Factores de Riesgo Identificados:** El análisis espacial y temporal confirma que los siniestros viales en moto no ocurren al azar; concentran patrones claros vinculados a las franjas horarias nocturnas/vespertinas, vías rápidas y variaciones estacionales.
3. **Aporte al Negocio:** El modelo desarrollado permite a los planificadores urbanos y autoridades de tránsito responder a la pregunta de negocio planteada, estimando dónde y cuándo se incrementa estadísticamente la probabilidad de siniestros viales en moto para el año 2024, orientando así patrullajes preventivos, campañas de concientización y controles de seguridad vial focalizados.